

Forschungsprojekt und Seminar

Computer Science

# Handgestenerkennung mit Entscheidungsbäumen

von

Tom Dymel

Februar 2021

Betreut von

Dr. Venzke

Institute of Telematics, Hamburg University of Technology

Erstprüfer

Prof. Dr. Volker Turau

Institute of Telematics  
Hamburg University of Technology

Zweitprüfer

Dr. Venzke

Institute of Telematics  
Hamburg University of Technology



# Inhaltsverzeichnis

<b>1</b>	<b>Einleitung</b>	<b>1</b>
<b>2</b>	<b>Methoden</b>	<b>3</b>
2.1	Entscheidungsbäume . . . . .	3
2.1.1	Konstruktion . . . . .	4
2.2	Ensemble-Methoden . . . . .	4
2.2.1	Wahlen . . . . .	5
2.2.2	Bagging . . . . .	5
2.2.3	Random Forest . . . . .	5
2.2.4	Extremely Randomized Trees . . . . .	6
2.2.5	Boosting . . . . .	6
<b>3</b>	<b>Stand der Forschung</b>	<b>7</b>
3.1	Ähnliche Arbeiten . . . . .	7
3.2	Fallstudie: Optische Handgestenerkennung . . . . .	8
3.2.1	Extrahierung von Gestenkandidaten . . . . .	8
3.2.2	Skalierung des Gestenkandidaten . . . . .	10
3.2.3	Trainings- und Testdaten . . . . .	10
3.2.4	Gestenerkennung mit künstliche neuronalen Netzen . . . . .	11
<b>4</b>	<b>Achievements</b>	<b>15</b>
4.1	Infrastructure . . . . .	15
4.1.1	Parsing gestures . . . . .	15
4.1.2	Feature extraction . . . . .	15
4.1.3	Training . . . . .	15
4.1.4	Arduino . . . . .	15
4.1.5	Utility Tools . . . . .	15
4.1.6	Workflow? . . . . .	15
4.2	DymelData . . . . .	15
4.2.1	Configurations . . . . .	16
4.2.2	NullGestures . . . . .	16
4.2.3	Synthetic Brightness Dataset . . . . .	16
4.3	Features . . . . .	16
4.3.1	Requirements . . . . .	16
4.3.2	Curse of dimensionality . . . . .	16
4.3.3	Unpromising features . . . . .	16
4.3.4	Brightness distribution . . . . .	16
4.3.5	Motion History . . . . .	16
4.3.6	Center of Gravity Distribution . . . . .	16
4.4	Performance Evaluation . . . . .	17
4.4.1	Testsets . . . . .	17

## INHALTSVERZEICHNIS

4.4.2	Feasible solution . . . . .	17
4.4.3	Considering NullGestures . . . . .	17
4.4.4	Brightness Distribution . . . . .	17
4.4.5	Motion History . . . . .	17
4.4.6	Brightness Distribution and Motion History . . . . .	18
4.4.7	Center of Gravity Distribution Float Ansatz . . . . .	18
4.4.8	Center of Gravity Distribution Integer Ansatz . . . . .	18
4.4.9	Center of Gravity Distribution Float and Integer Ansatz . . . . .	18
4.4.10	Comparison to previous work . . . . .	18
4.5	Execution Time Evaluation . . . . .	18
4.5.1	WCEP and WCET . . . . .	18
4.5.2	AVR Compiler for AtMega328p . . . . .	18
4.5.3	Optimization Level . . . . .	18
4.5.4	Feature extraction . . . . .	19
4.5.5	Tree Evaluation . . . . .	19
4.5.6	Forest Evaluation . . . . .	19
4.5.7	Total Execution Time . . . . .	19
4.6	Size Evaluation . . . . .	19
4.6.1	CCP (TODO: Abrev.) . . . . .	19
4.6.2	Minimum Leaf Sample Size . . . . .	19
<b>5</b>	<b>Conclusion</b>	<b>21</b>
	<b>Literaturverzeichnis</b>	<b>23</b>
<b>A</b>	<b>Content of the DVD</b>	<b>25</b>

## Einleitung

Machinelles Lernen (ML) gewann in den vergangenen Jahren an Popularität, u.a. durch die Fortschritte in parallelen Rechnen, sinkende Speicherpreise, schnelleren Speicher und den Zugang zu Bibliotheken, wie zum Beispiel Scikit-Learn, Keras und PyTorch, welche den Einstieg in maschinelles Lernen erleichtern (TODO: Quelle?). Ein namenhaftes Beispiel für das Potential von maschinellem Lernen ist die AlphaGo-KI, die einen Sieg gegen den besten menschlichen Spieler erringen konnte in dem Spiel Go, welches als besonders schwierig für Computer zu meistern galt durch den enormen Suchraum von möglichen Aktionen (TODO: Quelle).

Ein häufiges Anwendungsgebiet in eingebetteten Systemen ist die optische Gestenerkennung, die zur kontaktlosen Interaktion mit technischen Geräten u. a. genutzt wird (TODO: Quelle). Die eingesetzten Micro-Controller sind jedoch häufig nicht ausreichend leistungsfähig, um ein trainiertes Modell in passabler Zeit auszuführen (TODO: Quelle). Gründe dafür sind Kosten oder Anforderungen an die Batterielebensdauer (TODO: Quelle). Eine Lösung ist das Auslagern der Modelle in einen leistungsfähigen Rechencluster, indem die nötigen Eingabedaten auf dem Mikro-Controller gesammelt werden und anschließend an den Rechencluster gesendet werden (TODO: Quelle). Dies erzeugt allerdings Latenz und eine Abhängigkeit zu einer solchen Infrastruktur. Ein alternativer Ansatz ist das lokale Ausführen der Modelle, was allerdings die Komplexität des Modells limitiert um eine passable Ausführungszeit zu gewährleisten.

In dieser Arbeit wird die Handgestenerkennung mit Entscheidungsbäumen auf dem Arduino-Board ATmega328P untersucht, das mit 9 Fotowiderständen ausgestattet ist, die in einer 3x3 Matrix angeordnet sind. Der ATmega328P verfügt über eine 8-Bit APU, 2 kB RAM, 32 kB Flash-Speicher und operiert unter 16 MHz. Im Vergleich zu vorherigen Arbeiten, die sich mit Künstlichen Neuronalen Netzen (KNN) auseinandergesetzt haben, versprechen Entschei-

## 1 EINLEITUNG

dungsbäume einen geringeren Rechenaufwand.

Um dieses Ziel zu erreichen, werden Entscheidungsbaum basierte Klassifizierer auf einem leistungsstarken Computer trainiert und anschließend in eine bestehende Infrastruktur eingebettet, die Gestenkandidaten als Folge von Bildern identifiziert. Es werden insgesamt zwei Komponenten hinzugefügt. Die erste Komponente extrahiert Features, welche an die zweite Komponente, der Klassifizierer, weitergegeben werden um die Handgesten zu erkennen. Der Klassifizierer wird mit den vorherigen Arbeiten verglichen im Hinblick auf Ausführungszeit, Ressourcenverbrauch und Erkennungsgenauigkeit unter verschiedenen Verhältnissen, wie Geschwindigkeit, Licht und Entfernung. Zusätzlich wird untersucht inwiefern Nullgesten, i. e. invalide Gesten, erkannt werden können und welche Konsequenzen es auf die Erkennungsgenauigkeit hat.

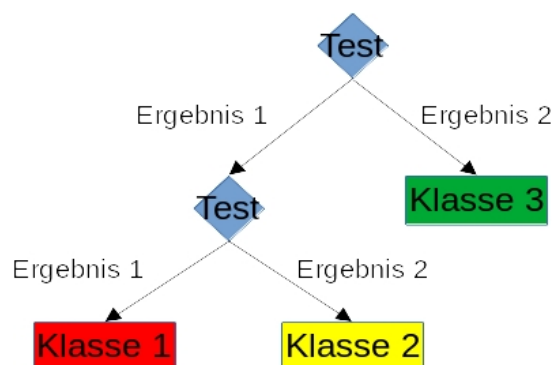
Zunächst werden in Kapitel 2 Entscheidungsbäume eingeführt, verschiedene Ensemble-Methoden erläutert und auf die Generierung von den Modellen eingegangen. In Kapitel 3 wird erläutert, wie Gestenkandidaten extrahiert werden und welche Ansätze vorherige Arbeiten bereits verfolgt hatten. Anschließend präsentiert Kapitel 4 den Kern der Arbeit. Zuallererst wird die Infrastruktur vorgestellt, welche im Rahmen dieser Arbeit angefertigt wurde, um Klassifizierer zu trainieren und zu evaluieren. Anschließend wird das Datenset `Dymel` vorgestellt, was zusätzlich zu dem bestehenden Datenset von `Klisch` erstellt wurde, um Nullgesten zu und verschiedene Helligkeitsstufen zu untersuchen. Danach werden die Features vorgestellt, die im Laufe dieser Arbeit untersucht wurden. Zuletzt wird die Erkennungsgenauigkeit, die Ausführungsgeschwindigkeit und der Ressourcenverbrauch evaluiert. In Kapitel 5 werden die Schlussfolgerungen dargestellt.

## Methoden

Dieses Kapitel verschafft einen Überblick über die genutzten Methoden und erläutert in dem Zusammenhang Begrifflichkeiten die für das Verständnis dieser Arbeit relevant sind. Zuerst wird der Entscheidungsbaum vorgestellt und wie man ihn trainiert und anschließend die in dieser Arbeit genutzten Ensemble-Methoden.

### 2.1 Entscheidungsbäume

Der Entscheidungsbaum ist eine rekursive Datenstruktur um Entscheidungsregeln darzustellen. Jedem Blatt ist eine Klasse zugeordnet und allen anderen Knoten ist ein *Test* zugeordnet. Der Test hat eine Reihe von sich gegenseitig ausschließenden Ergebnissen. Die Zuordnung einer Klasse zu einem Objekt wird durch das Traversieren dieses Baumes bestimmt bis ein Blatt erreicht wird [Qui90]. Abbildung 2.1 zeigt einen Entscheidungsbaum, wo jeder Test zwei mögliche Ergebnisse hat, i. e. einen binären Entscheidungsbaum. Möglich wäre aber auch das jeder Test eine arbiträre Anzahl an möglichen Ergebnissen hätte.



■ **Abbildung 2.1:** Beispiel eines binären Entscheidungsbaums mit 3 möglichen Klassen, die klassifizierbar sind.

### 2.1.1 Konstruktion

Es gibt viele verschiedene Algorithmen um Entscheidungsbäume zu erzeugen: ID3, C4.5, C5, CART, CHAID, QUEST, GUIDE, CRUISE and CTREE. Am häufigsten wird ID3 (Iterative Dichotomizer 3), bzw. C4.5, welches eine Weiterentwicklung von ID3 ist, und CART (Classification and Regression Trees) verwendet [PVG<sup>+</sup>11, SG14]. Diese Arbeit verwendet die Implementierung für Entscheidungsbaumklassifizierer von *Scikit-Learn*, die eine optimierte Version von CART nutzt [Ent20]. Scikit-Learn ist ein Python-Modul, das eine große Auswahl von Algorithmen zum maschinellen Lernen implementiert [PVG<sup>+</sup>11].

### CART: Classification and Regression Trees

Die Konstruktion eines optimalen binären Entscheidungsbaum ist NP-Komplett [LR76]. CART ist ein Greedy-Algorithmus, der lokal immer die beste Teilung wählt.

```
Weise dem Wurzelknoten alle Trainingsdaten zu.
Definiere den Wurzelknoten als Blatt.
WHILE True:
    Neue_Teilungen = 0
    FOR jedes Blatt:
        IF die Größe der zugewiesenen Trainingsdaten zu klein ist oder alle ✓
           Einträge der Trainingsdaten zur gleichen Klasse gehören:
            CONTINUE
        Finde das Attribut, das am besten den Knoten in zwei Kindesknöten ✓
           unterteilt mit einer erlaubten Teilungsregel.
        Neue_Teilungen += 1
    IF Neue_Teilungen == 0:
        break
```

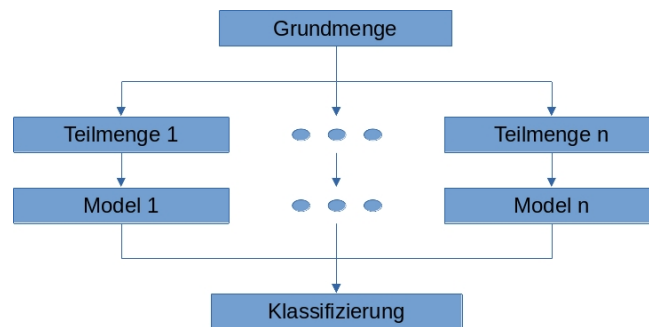
■ **Listing 2.1:** Skizze von vereinfachten Baumwachstumsalgorithmus [Ste09].

Listing 2.1 skizziert wie CART initial einen maximal großen Baum generiert indem die Trainingsdaten solange geteilt werden bis keine weitere Teilung mehr möglich ist oder alle Einträge der gleichen Klasse zugeordnet sind. Zuletzt beginnt der Reduzierungsprozess indem Teilbäume gelöscht werden, die die Klassifizierungsgenauigkeit nicht erhöhen oder der Zuwachs unter einem Nutzer definierten Schwellenwert liegt [Ste09].

## 2.2 Ensemble-Methoden

Oftmals ist der Suchraum für das Problem zu groß, als das es möglich wäre in tolerabler Zeit die optimale Lösung zu finden [LR76]. Konstruktionsalgorithmen für Entscheidungsbäume arbeiten aus diesem Grund auf Basis von Heuristiken um die lokal optimale Teilung zu bestimmen. Im Gegensatz zu diesen Algorithmen versuchen Ensemble-Methoden nicht die





■ **Abbildung 2.2:** Klassifizierungsprozess mit der Bagging-Methode.

beste Lösung, sondern konstruieren eine Menge von Lösungen unter denen anschließend gewählt wird, was die finale Lösung für ein Problem ist [D<sup>+</sup>02].

### 2.2.1 Wählen


Formal wird also ein „Wahl“-Klassifizierer  $H(x) = w_1 h_1(x) + \dots + w_K h_K(x)$  geschaffen, mit Hilfe von einer Menge von Lösungen  $\{h_1, \dots, h_K\}$  und einer Menge von Gewichten  $\{w_1, \dots, w_K\}$ , wobei  $\sum_i w_i = 1$ . Eine Lösung  $h_i : D^n \mapsto \mathbb{R}^m$  weist einer arbiträren,  $n$ -dimensionalen Menge  $D^n$  jeder der  $m$  möglichen Klassen eine Wahrscheinlichkeit zu. Die Summe einer Lösung ist immer 1. Die Klassifizierung einer Lösung ist die Klasse mit der höchsten Wahrscheinlichkeit. Dementsprechend ist analog dazu  $H : D^n \mapsto \mathbb{R}^m$  definiert. Für gewöhnlich hat jeder Teilnehmer einer Wahl das gleiche Gewicht [D<sup>+</sup>02].

### 2.2.2 Bagging

Bagging ist ein Acronym für „**B**ootstrap **a**ggregating“. Die Idee ist aus einer großen Menge von Trainingsdaten, eine Menge von Mengen von Trainingsdaten zu generieren, folgend mit jedem dieser Mengen einen Klassifizierer zu trainieren und schließlich alle Klassifizierer, e.g. durch Wählen, zu aggregieren (siehe Abbildung 2.2) [Bre96]. Die Methode die dahinter steht nennt sich „Bootstrap sampling“, welche einen Prozess beschreibt aus einer Grundmenge  $m$  mal jeweils  $n$  Einträge zu ziehen, die eine Teilmenge bilden [Efr92]. Der Name ist folglich aus der Methode und dem Aggregierungsprozess abgeleitet.

### 2.2.3 Random Forest

Random Forest ist eine Erweiterung der Bagging-Methode. Zusätzlich zu der zufällig ausgewählten Menge an Trainingsdaten wird auch zufällig eine Menge von Features ausgewählt. Auf dieser Basis wird eine Menge von Entscheidungsbäumen generiert die anschließend aggregiert werden [Bre01].



■ **Abbildung 2.3:** Klassifizierungsprozess mit der Boosting-Methode.

### 2.2.4 Extremely Randomized Trees

Im Vergleich zu Random Forest gehen Extremely Randomized Trees einen Schritt weiter. Anstatt den besten Teilungspunkt zu suchen für die ausgewählten Features, werden zufällig ein Teilungspunkte ausgewählt, aus denen der beste genutzt wird. Dies soll die Varianz reduzieren. Außerdem wird nicht wie bei der Bagging-Methode auf Teilmengen trainiert sondern auf dem gesamten Set, was den Bias reduzieren soll [GEW06].

### 2.2.5 Boosting

Boosting bezeichnet das Konvertieren eines „schwachen“ PAC-Algorithmus (**P**robably **A**pproximately **C**orrect), welcher nur leicht besser ist als Raten, in einen „starken“ PAC-Algorithmus. Ein starker PAC-Algorithmus ist ein Algorithmus der, gegeben  $\epsilon, \delta > 0$  und zufällige Beispiele der Trainingsdaten, mit einer Wahrscheinlichkeit  $1 - \delta$  klassifiziert mit einem Fehler bis zu  $\epsilon$  und die Laufzeit muss polynomial in  $\frac{1}{\epsilon}, \frac{1}{\delta}$  und anderen relevanten Parametern sein. Für einen schwachen PAC-Algorithmus gilt das Gleiche mit dem Unterschied, dass  $\epsilon \geq \frac{1}{2} - \gamma$ , wobei  $\delta > 0$  [FS97].

In Abbildung 2.3 wird illustriert wie drei schwache Lerner jeweils auf eine Teilmenge nacheinander trainiert werden, wobei die Teilmenge des jeweils nächsten von dem Fehler des vorherigen Models abhängt. Schlussendlich werden alle schwachen Lerner gewichtet aggregiert woraus ein starker Lerner entsteht. In dieser Arbeit wird im speziellen der Boosting Algorithmus **AdaBoost** von Freund und Schapire verwendet [FS97].


## Stand der Forschung

Dieses Kapitel verschafft einen Überblick über bisherige Arbeiten im Bereich der Gestenerkennung. Zuerst wird allgemein auf die Gestenerkennung mit Entscheidungsbäumen eingegangen. Anschließend wird der Ansatz zur optischen Gestenerkennung vorgestellt, der im Institut für Telematik an der TUHH entwickelt wurde. Zuletzt wird auf die Ergebnisse von bisherigen Arbeiten mit künstlichen neuronalen Netzen mit diesem Ansatz eingegangen.

### 3.1 Ähnliche Arbeiten

Es gibt viele Ansätze, die sich mit der Gestenerkennung beschäftigen. Es wird unterschieden zwischen optischen und nicht-optischen Ansätzen. Der optische Ansatz nutzt einen oder mehrere Kameras um eine Folge von Bildern aufzunehmen. Ein populäres Beispiel dafür ist die Kinect. Dieser Ansatz ist allerdings empfindlich gegenüber Lichtverhältnisse und der Distanz die der Nutzer zu den Kameras hat [SHL<sup>+</sup>19]. Nicht-optische Ansätze bedienen sich anderen Sensoren, z. B. Infrarot Abstandssensoren [CCRB11], oder nutzen technische Hilfsmittel um zusätzliche Daten zu erfassen, z. B. einen tragbaren sEMG Recorder der die elektrischen Signale der Muskelaktivitäten erfasst [SHL<sup>+</sup>19].

Die Gestenerkennung ist Teil der Mensch-Computer Interaktion und ein häufig genanntes Anwendungsgebiet die Gebärdensprachenerkennung [FGZ03]. Kadous demonstrierte eine Erkennungswahrscheinlichkeit von 80% bei einer Auswahl von 95 australischen Gebärden mit einem Entscheidungsbaum basierten Ansatz der die Daten eines Power-Gloves nutzt [K<sup>+</sup>96]. Cheng et al. demonstrierten eine Erkennungswahrscheinlichkeit von 98% in Echtzeit bei einer Auswahl von 4 3D-Gesten mit einem Entscheidungsbaum basierten Ansatz der lediglich die Daten eines Infrarot Abstandssensor nutzt [CCRB11].



■ **Abbildung 3.1:** Das Arduino-Board ATmega328P mit 3x3 Matrix von Lichtsensoren in Lego-Verpackung. Illustriert werden die möglichen Handgestentypen mit Ausnahme der Nullgeste.

## 3.2 Fallstudie: Optische Handgestenerkennung

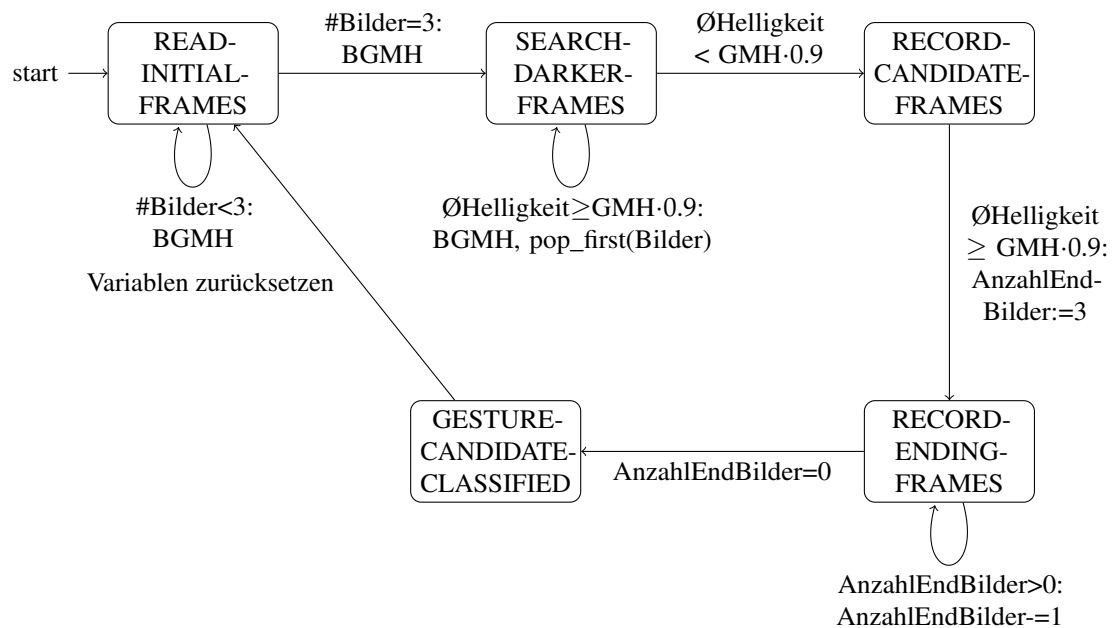
Diese Arbeit ist Teil einer Fallstudie zur Handgestenerkennung auf Low-End Mikro-Controllern von dem Institut für Telematik an der TUHH [VKK<sup>+</sup>20]. Das Ziel ist die Handgestenerkennung in Echtzeit mit so wenig Ressourcen wie möglich, damit die Produktion der einzelnen Module so kostengünstig wie möglich ist. Als Eingabe dient, je nach Modul, eine 3x3, bzw. 4x4, Matrix von Lichtsensoren. Dabei werden 5 Typen von Handgesten untersucht: Links nach Rechts, Rechts nach Links, Oben nach Unten, Unten nach Oben und NullGeste, i. e. eine invalide Geste (siehe Abbildung 3.1). Die bisherigen Arbeiten haben sich mit künstlichen neuronalen Netzen beschäftigt. Dessen Prozessablauf zur Gestenerkennung lässt sich im Grunde auf 3 Schritte zusammenfassen.

1. Extrahiere einen Gestenkandidaten.
2. Vorverarbeite den Gestenkandidaten.
3. Wende das Model auf die vorverarbeiteten Daten an.

### 3.2.1 Extrahierung von Gestenkandidaten

Die Lichtsensorenmatrix liefert einen kontinuierlichen Strom an Bildern. Dabei limitiert die Verarbeitungszeit eines Bildes die Anzahl an Bilder pro Sekunde. Als Gestenkandidat wird eine Folge von Bildern definiert, die ein Ereignis einschließt. In diesem Fall wird das Ereignis durch die Veränderung im gleitenden Mittelwert der Lichtverhältnisse definiert, i. e. sobald

### 3.2 FALLSTUDIE: OPTISCHE HANDGESTENERKENNUNG



■ **Abbildung 3.2:** Implementierung von Kubik's Algorithmus um Gestenkandidaten zu erkennen von Dr. Marcus Venzke. BGMH steht für die Aktion „Berechnung Gleitender Mittelwert der Helligkeit“ und GMH steht für die Variable „Gleitender Mittelwert der Helligkeit“.

der gleitende Mittelwert unterschritten wird ein Gestenkandidat angefangen aufgenommen zu werden und sobald die Lichtverhältnisse zu dem Wert zurückkehren wird die Aufnahme beendet. Der gleitende Mittelwert wird dabei immer angepasst, wenn kein Gestenkandidat aufgenommen wird, um sich den veränderten Lichtverhältnissen anzupassen. Da leichte Veränderungen natürlich sind, muss eine Toleranzgrenze von 10% unterschritten werden, damit die Aufnahme gestartet wird. Dies hat als Folge, dass der Anfang und das Ende nicht vollständig ist. Aus diesem Grund schlug Kubik zusätzlich vor am Anfang und Ende weitere Bilder anzufügen [Kub19].

Abbildung 3.2 zeigt die konkrete Implementierung dieses Algorithmus mit einem Zustandsautomaten von Dr. Marcus Venzke. In jedem Zustand wird das aktuelle Bild dem Puffer angefügt. Der Automat verbleibt im Zustand `READ-INITIAL-FRAMES` bis der Puffer 3 Bilder enthält und passt stets den gleitenden Mittelwert der Helligkeit an. Anschließend geht der Automat in den Zustand `SEARCH-DARKER-FRAMES` über, indem er weiterhin den gleitenden Mittelwert anpasst und immer das erste Bild aus dem Puffer entfernt, da lediglich 3 Bilder jeweils vorm Aufnehmen und nach dem Aufnehmen des Gestenkandidates angefügt werden sollen. Sobald die Durchschnittshelligkeit den 90% des gleitenden Mittelwerts unterschreitet wird die Aufnahme begonnen. Der Automat geht in den Zustand `RECORD-CANDIDATE-FRAMES` über. Dort verbleibt der Automat solange bis die Durchschnittshelligkeit 90% des gleitenden Mit-

### 3 STAND DER FORSCHUNG

telwerts überschreitet, woraufhin der Automat in den Zustand `RECORD-ENDING-FRAMES` über geht, indem die letzten 3 Bilder an den Puffer angehängt werden. Der Zustand des Puffers im Zustand `GESTURE-CANDIDATE-CLASSIFIED` repräsentiert den Gestenkandidaten. Zuletzt werden alle nötigen Variablen zurückgesetzt und der Automat geht in den initialen Zustand wieder über.

#### 3.2.2 Skalierung des Gestenkandidaten


Ein Gestenkandidat besteht aus einer variablen Anzahl an Bildern. Durch die künstlich angefügten Bilder am Anfang und Ende sind es mindestens 8 Bilder. Kubik erkannte, dass ein neuronales Netz eine feste Anzahl an Eingaben hat und diskutierte verschiedene Ansätze. Er verwarf die Idee den Puffer mit irrelevanten Bildern oder Nullen auszufüllen, Bilder zu duplizieren oder Teile des Gestenkandidaten zu verwerfen, da dadurch nicht die vollständige Geste auf die Eingangs-Ebene abgebildet werden würde, oder dass die Geste womöglich verzerrt wäre. Aus diesem Grund hat Kubik sich für lineare Interpolation auf eine fixe Anzahl von 20 Bildern entschieden im Falle wenn weniger als 20 Bilder vorhanden sind. Im Falle, wenn mehr als 20 Bilder vorhanden sind, werden 20 Bilder gleichverteilt ausgewählt [Kub19]. Dieser Ansatz wurde auch von Anton Giese aufgegriffen, der sich in diesem Zusammenhang ebenfalls mit künstlichen neuronalen Netzen beschäftigt hatte [Gie20].

#### 3.2.3 Trainings- und Testdaten

```
...  
665,683,669,690,627,670,672,611,557,1  
662,679,657,676,564,592,633,467,415,1  
645,653,583,627,549,483,598,474,230,1  
576,444,269,488,251,209,352,184,187,1  
361,254,123,343,130,82,304,83,36,1  
131,69,41,120,34,39,72,25,30,1  
49,71,174,61,45,206,40,45,110,1  
111,242,473,113,195,467,122,210,343,1  
272,559,637,304,518,639,401,553,562,1  
566,646,654,592,580,654,634,618,602,1  
...
```

■ **Listing 3.1:** Beispiel einer gespeicherten Handgeste von Links nach Rechts.

Die Modelle werden auf Basis von aufgenommenen Daten trainiert und getestet. Jedes aufgenommene Bild wird durch einen Komma separierten Vektor von Zahlen dargestellt gefolgt von einer Annotation für den Gestentyp. Eine Geste ist eine Folge von Bildern, die die gleiche Annotation teilen (siehe Listing 3.1). Insgesamt gibt es 4792 Aufnahmen von validen Handgesten, die unter verschiedenen Lichtverhältnissen und Distanzen zur Kamera aufgenom-



**Abbildung 3.3:** Illustration der Handgeste von Links nach Rechts aus Listing 3.1.

men wurden. Dabei wurde die Gesten mit der Hand und Finger ausgeführt in verschiedenen Geschwindigkeiten (TODO: Quelle?!).

#### Synthetische Daten

Um die Datenmenge zu erhöhen, können synthetisch Daten aus den bestehenden Daten erzeugt werden indem sie rotiert werden, Rauschen hinzugefügt wird oder die Helligkeit, Kontraste oder Gamma verändert wird [VKK<sup>+</sup>20].

#### Testdaten und Metrik von Klisch

Als Testdaten wird ein Teil der Datenmenge bezeichnet, die nicht zum trainieren verwendet wurde. Kubik hat Testdaten unter verschiedenen Lichtverhältnissen und Entfernungen zur Kamera aufgenommen. Klisch hat daraus eine Testmenge erstellt die von Klisch und Giese zur Verifikation verwendet wurden [Kli20, Gie20]. Klisch definiert die Erkennungsgenauigkeit als Verhältnis zwischen der Anzahl an korrekt erkannten Gesten und der Gesamtanzahl (siehe Formel 3.1) [Kli20].

$$accuracy = \frac{\#true\ positives}{\#total\ gestures} \quad (3.1)$$

#### 3.2.4 Gestenerkennung mit künstliche neuronalen Netzen

Insgesamt gingen dieser Arbeit 4 Arbeiten voraus, die sich mit künstlichen neuronalen Netzen im Zusammenhang dieser Fallstudie beschäftigt hatten.

#### Engelhardt

Engelhardt führte die in 3.2 definierten Handgesten mit der Hand, einem Finger und 2 Finger unter verschiedenen Helligkeiten aus, auf Basis dessen seine Modelle trainiert und validiert

### 3 STAND DER FORSCHUNG

wurden. Er argumentiert, dass rekurrente neuronale Netze (RNN), Feedforward neuronale Netze (FFNN) und Long-Short-Term Memory neuronale Netze (LSTMNN) am besten geeignet für temporale Probleme seien. Convolutional neuronale Netze (CNN) verwarf Engelhardt aufgrund der geringen Auflösung der Gesten und da die Faltung extrem Rechenaufwendig sei. Desweiteren verwarf er LSTMNN, da diese zu viel Rechenleistung und Speicherplatz benötigen. Als Eingabewerte zu seinen RNNs und FFNNs diente eine Sequenz von 20 Bilder die zu 180 Werten konkatinert wurden und auf Werte zwischen 0 und 1 normalisiert wurden. Als bestes Model stellte sich eines seiner FFNNs heraus, das auf seinen Testdaten bis zu 99% Erkennungsgenauigkeit erzielte. Außerdem erwies es sich als robust gegenüber Rauschen und Helligkeitsveränderungen im Vergleich zum RNN. Die Ausführungszeit des FFNN belief sich auf 11,54 ms mit einem Verbrauch von 11 kB Flash-Speicher und 573 bytes RAM [Eng18].

#### Kubik

Kubik hat in seiner Arbeit den FFNN Ansatz von Engelhardt aufgegriffen. Er untersuchte Gesten die mit der Hand ausgeführt werden mit verschiedenen Distanzen zur Kamera und unter guten und schlechten Lichtverhältnissen. Neben der Facettenkamera, die Engelhardt ebenfalls genutzt hatte, untersuchte Kubik ebenfalls eine Lochkamera. Er stellte fest, dass diese aber wesentlich schwerer war auszuleuchten, was sich auch bei der Erkennungsgenauigkeit bemerkbar machte. Als Eingabe nutze Kubik ebenfalls 180 Werte, die 20 Bilder repräsentieren. Um mit der variablen Länge von Gesten umzugehen schlug Kubik vor die Bildsequenzen auf 20 Bilder zu skalieren (siehe Sektion 3.2.2). Um die Skalierung durchzuführen musste allerdings der Anfang und das Ende der Geste bekannt sein. Aus diesem Grund war es nötig Gestenkandidaten erkennen zu können (siehe Sektion 3.2.1). Er stellte fest, dass dies die Gesamtlänge der Geste limitierte in Abetracht des RAMs von dem Arduino. Um die Erkennungsgenauigkeit zu erhöhen verwendete er synthetische Trainingsdaten, die er aus bestehenden Daten durch Rotation generierte (siehe Sektion 3.2.3). Dies erhöhte die Erkennungsgenauigkeit erheblich. Kubik erstellte Testdaten (siehe Sektion 3.2.3) und evaluierte sein Model darauf. Im allgemeinen stellte er fest, dass mit zunehmender Distanz zur Kamera die Erkennungsgenauigkeit sich verschlechtert. Dies erwies sich besonders als ein Problem für die Lochkamera. Bei guten Lichtverhältnissen konnte sein Ansatz mit der Facettenkamera bis 30 cm eine Erkennungsgenauigkeit von 97,2% erreichen. Bei schlechten Lichtverhältnissen war die Erkennungsgenauigkeit bereits ab 20 cm nur noch bei 83%. Zusätzlich zu den 4 Grundgesten, untersuchte Kubik Nullgesten. Er stellte fest, dass ruckartige Veränderungen der Lichtverhältnisse mit 92% erkannt wurden und Handbewegungen die wieder zurück gezogen wurden mit 96%. Schwierigkeiten hat die Erkennung von diagonalen Bewegungen als Nullgeste bereitet, da diese eine hohe Ähnlichkeit zu der benachbarten horizontalen und vertikalen



### 3.2 FALLSTUDIE: OPTISCHE HANDGESTENERKENNUNG

Geste hat. Kubiks Ansatz hat insgesamt 36 ms benötigt um das Model auszuwerten und 11 ms für die Skalierung [Kub19].

**Klisch**

**Giese**

### 3 STAND DER FORSCHUNG

# Achievements

TODO Also talk somewhere about the training sets. Here we can also mention cherry picking, since I cant find any source that mentions something along those lines.

## 4.1 Infrastructure

### 4.1.1 Parsing gestures

### 4.1.2 Feature extraction

### 4.1.3 Training

Scikit-Learn

Ensemble

### 4.1.4 Arduino

Export Tree as C code

Feature extraction

### 4.1.5 Utility Tools

Gesture Recorder

Playground

Gesture Simulation

### 4.1.6 Workflow?

## 4.2 DymelData

TODO: Motivation @ consistent real world evaluation

## 4 ACHIEVEMENTS

### 4.2.1 Configurations

### 4.2.2 NullGestures

Explain what it is in general

**Corner**

**Same side in and out**

**Rotations**

### 4.2.3 Synthetic Brightness Dataset

## 4.3 Features

### 4.3.1 Requirements

**Invariance to velocity**

**Development over time**

**Sense of direction**

**Sense of position**

### 4.3.2 Curse of dimensionality

### 4.3.3 Unpromising features

Explain that they had been tried out and did work out. Explain why

### 4.3.4 Brightness distribution

Explain what it is. Note this as "discretized" position. Explain what requirements it fulfills. Explain different variants.

### 4.3.5 Motion History

Explain origin and how it works. Explain what requirements it fulfills and why.

**Implementation**

### 4.3.6 Center of Gravity Distribution

Motivate.?

**Center of Gravity**

**Integer variant**

**Adding development over time**

**Window size**

Also talk about the squishing?

### 4.4 Performance Evaluation

Talk about what was searched for, i.e. not all sizes had been tried out. Talk about different testset sizes? Talk about the greedy nature of the training algorithm? (Was that done in Cherry Picking?)

#### 4.4.1 Testsets

Motivate. Explain what they are used for. Explain whats in there?

#### Metrics

Talk about used metrics

**Klisch**

**DymelNull**

**DymelGesture**

#### 4.4.2 Feasible solution

#### 4.4.3 Considering NullGestures

#### 4.4.4 Brightness Distribution

Show graphs about: Best solution, Best feasible solution, With and WithOUT considering null gestures. Talk when it starts to generalize more poorly(?)

#### 4.4.5 Motion History

Show graphs about: Best solution, Best feasible solution, With and WithOUT considering null gestures. Talk when it starts to generalize more poorly(?)

## 4 ACHIEVEMENTS

### 4.4.6 Brightness Distribution and Motion History

Show graphs about: Best solution, Best feasible solution, With and WithOUT considering null gestures. Talk when it starts to generalize more poorly(?)

### 4.4.7 Center of Gravity Distribution Float Ansatz

Show graphs about: Best solution, Best feasible solution, With and WithOUT considering null gestures. Talk when it starts to generalize more poorly(?)

Talk about brightness distribution!!

### 4.4.8 Center of Gravity Distribution Integer Ansatz

Show graphs about: Best solution, Best feasible solution, With and WithOUT considering null gestures. Talk when it starts to generalize more poorly(?)

Talk about brightness distribution!!

### 4.4.9 Center of Gravity Distribution Float and Integer Ansatz

Show graphs about: Best solution, Best feasible solution, With and WithOUT considering null gestures. Talk when it starts to generalize more poorly(?)

Here state what was expected and state how it worked out! Talk about brightness distribution!! ==> Alternative approach ==> Stacking (?)

### 4.4.10 Comparison to previous work

## 4.5 Execution Time Evaluation

Talk about constrained micro controller. Say that more frames potentially give more insight about fast gestures or that a longer battery life can be achieved. Say that we only consider COCD here, because that has the best feasible solution.

### 4.5.1 WCEP and WCET

### 4.5.2 AVR Compiler for AtMega328p

### 4.5.3 Optimization Level

Say that we considered O2 since the feasible solution can be compiled in O2. And why its a good Kompromiss between O3 and Os

### 4.5.4 Feature extraction

### 4.5.5 Tree Evaluation

### 4.5.6 Forest Evaluation

Here mainly talk about voting.

### 4.5.7 Total Execution Time

## 4.6 Size Evaluation

Explain that scikit learn provides some hyperparameters that can be changed. Elaborate which exist. Say that I considered here two parameters because all ensemble methods supported that. Maybe other reasons.

### 4.6.1 CCP (TODO: Abrev.)

### 4.6.2 Minimum Leaf Sample Size

## 4 ACHIEVEMENTS



## Conclusion

Do a summary. Should be brief but also name everything and its result more or less. Say the improvement compared to the old approach. (Or downsides).

Mention future work. => Stacking

## 5 CONCLUSION

# Literaturverzeichnis

- [Bre96] BREIMAN, Leo: Bagging predictors. In: *Machine learning* 24 (1996), Nr. 2, S. 123–140
- [Bre01] BREIMAN, Leo: Random forests. In: *Machine learning* 45 (2001), Nr. 1, S. 5–32
- [CCRB11] CHENG, Heng-Tze ; CHEN, An M. ; RAZDAN, Ashu ; BULLER, Elliot: Contactless gesture recognition system using proximity sensors. In: *2011 IEEE International Conference on Consumer Electronics (ICCE)* IEEE, 2011, S. 149–150
- [D<sup>+</sup>02] DIETTERICH, Thomas G. u. a.: Ensemble learning. In: *The handbook of brain theory and neural networks* 2 (2002), S. 110–125
- [Efr92] EFRON, Bradley: Bootstrap methods: another look at the jackknife. In: *Breakthroughs in statistics*. Springer, 1992, S. 569–593
- [Eng18] ENGELHARDT, Sebastian: Optische Gestenerkennung mit künstlichen neuronalen Netzen für kleine eingebettete Systeme. (2018), 10, S. 1–53
- [Ent20] ENTWICKLER scikit-learn: 1.10.6. *Tree algorithms: ID3, C4.5, C5.0 and CART*. <https://scikit-learn.org/stable/modules/tree.html#tree-algorithms>. Version: 2020
- [FGZ03] FANG, Gaolin ; GAO, Wen ; ZHAO, Debin: Large vocabulary sign language recognition based on hierarchical decision trees. In: *Proceedings of the 5th international conference on Multimodal interfaces*, 2003, S. 125–131
- [FS97] FREUND, Yoav ; SCHAPIRE, Robert E.: A decision-theoretic generalization of on-line learning and an application to boosting. In: *Journal of computer and system sciences* 55 (1997), Nr. 1, S. 119–139
- [GEW06] GEURTS, Pierre ; ERNST, Damien ; WEHENKEL, Louis: Extremely randomized trees. In: *Machine learning* 63 (2006), Nr. 1, S. 3–42
- [Gie20] GIESE, Anton: Compression of Artificial Neural Networks for Hand Gesture Recognition. (2020), 10, S. 1–46
- [K<sup>+</sup>96] KADOUS, Mohammed W. u. a.: Machine recognition of Auslan signs using PowerGloves: Towards large-lexicon recognition of sign language. In: *Proceedings of the Workshop on the Integration of Gesture in Language and Speech* Bd. 165, 1996
- [Kli20] KLISCH, Daniel: Training of Recurrent Neural Networks as Multiple Feed Forward Networks. (2020), 01, S. 1–39
- [Kub19] KUBIK, Philipp: Zuverlässige Handgestenerkennung mit künstlichen neuronalen Netzen. (2019), 04, S. 1–47
- [LR76] LAURENT, Hyafil ; RIVEST, Ronald L.: Constructing optimal binary decision trees is NP-complete. In: *Information processing letters* 5 (1976), Nr. 1, S. 15–17

## LITERATURVERZEICHNIS

- [PVG<sup>+</sup>11] PEDREGOSA, F. ; VAROQUAUX, G. ; GRAMFORT, A. ; MICHEL, V. ; THIRION, B. ; GRISEL, O. ; BLONDEL, M. ; PRETTENHOFER, P. ; WEISS, R. ; DUBOURG, V. ; VANDERPLAS, J. ; PASSOS, A. ; COURNAPEAU, D. ; BRUCHER, M. ; PERROT, M. ; DUCHESNAY, E.: Scikit-learn: Machine Learning in Python. In: *Journal of Machine Learning Research* 12 (2011), S. 2825–2830
- [Qui90] QUINLAN, J R.: Decision trees and decision-making. In: *IEEE Transactions on Systems, Man, and Cybernetics* 20 (1990), Nr. 2, S. 339–346
- [SG14] SINGH, Sonia ; GUPTA, Priyanka: Comparative study ID3, cart and C4. 5 decision tree algorithm: a survey. In: *International Journal of Advanced Information Science and Technology (IJAIST)* 27 (2014), Nr. 27, S. 97–103
- [SHL<sup>+</sup>19] SONG, Wei ; HAN, Qingquan ; LIN, Zhonghang ; YAN, Nan ; LUO, Deng ; LIAO, Yiqiao ; ZHANG, Milin ; WANG, Zhihua ; XIE, Xiang ; WANG, Anhe u. a.: Design of a flexible wearable smart sEMG recorder integrated gradient boosting decision tree based hand gesture recognition. In: *IEEE Transactions on Biomedical Circuits and Systems* 13 (2019), Nr. 6, S. 1563–1574
- [Ste09] STEINBERG, Dan: Chapter 10 CART: Classification and Regression Trees. (2009), 01, S. 179–201
- [VKK<sup>+</sup>20] VENZKE, Marcus ; KLISCH, Daniel ; KUBIK, Philipp ; ALI, Asad ; DELL MISSIER, Jesper ; VOLKER, Turau: Artificial Neural Networks for Sensor Data Classification on Small Embedded Systems. (2020), 08, S. 1–25

## Content of the DVD

In this chapter, you should explain the content of your DVD.